

Robotik Kollarda Kestirimci Bakım

Kestirimci bakım yöntemleri, robotların mevcut aşınma durumunu yakalayıp geleceğe yönelik tahminlerde bulunur. Bu modeller fiziksel temelli veya veri temelli olabilir. Veri temelli modeller için, robotun farklı aşınma koşullarına ait verilerin toplanması ve bu veriler ile aşınma durumu arasında bir korelasyon bulunması gereklidir. Bu bağlamda, **titreşim sensörleri, sıcaklık sensörleri, akım sensörleri ve yağ analiz sensörleri** gibi çeşitli sensör sistemleri kullanılabilir.

Örnek çalışma: [predictive maintenance.pdf](#)

Metodoloji

İlk olarak, bir üretim tesisi tarafından tutulan bakım departmanı kayıtlarından **tarihsel hata verilerine** dayanarak arıza hassas robot parçaları belirlenmiş. Özellikle, fabrikadaki her arıza, ilişkili zaman damgası ve alınan bakım eylemini belirten bir bakım kaydı kullanılır. Bu veriyi robot parçalarına göre kümelendirerek, her bir bileşenin arıza sıklığı türetilir.

İkinci olarak, bu veriyi **uzman görüşmeleriyle** doğrulayarak hata ciddiyetini doğruluyoruz. Bu adımdaki amaç, hata yapılması muhtemel parçaların değiştirilmesi için gereken ekonomik süreyi değerlendirmektir. Yüksek değiştirme sürelerine sahip parça hataları, daha uzun duruş süreleriyle ve yüksek ilgili bakım maliyetleriyle sonuçlanır. Dolayısıyla, bu parçalar, tahmin edici bakım stratejisine odaklanılmalıdır.

Üçüncü olarak, bu parçalar için tipik hatalar türeterek, literatür verilerine ve bu hataları izlemek için uygun sensörlere dayanırız. Parçalar, hatalar ve sensörlerle ilgili verileri, graf tabanlı bir ontoloji içinde özetleriz. Bu graf, robot bileşenlerini, hataları, veri kaynaklarını ve yayınları temsil eden farklı düğüm sınıflarından oluşur. Bunlar, Tablo 1'de açıklanan farklı kenar sınıfları tarafından bağlanır.

Table 1. Node and edge classes

Node Class	Component	Publication	Data source	Fault
Component	is subcomponent		can be monitored with	
Publication	holds information regarding		holds information regarding	holds information regarding
Fault	appears in			

Dördüncü adımda, her veri kaynağını yayınlarla bağlayan kenarlar sayılır. Bu şekilde, her bir veri kaynağı düğümü için kullanım sıklığı belirlenebilir. İlgili hatalar için literatürde en sık kullanılan sensör sistemlerini PHM veri toplama sistemi için kullanmayı öneriyoruz.

Beşinci adımda, seçilen sensör sistemlerini dikkate alarak dört farklı kavramsal robot trajetuarını ve bu trajetuarlarla ilgili çeşitli kriterleri değerlendiririz. Bu değerlendirme uzman bilgisine dayandığından, sonuçlar, karşılaştırma yapacak kişilere ve dikkate alınacak üretim sistemine bağlı olarak değişebilir. Bu nedenle, güvenilir sonuçlar elde etmek için bu değerlendirmenin her bir üretim sistemi için ve birkaç uzmana danışılarak yapılması önerilir.

Veri sonuçları

En yüksek değerlendirme puanına sahip olan trajetuarın seçilir. Sensör işlem, altı eksenli bir robotun dişli kutusunun kasasına ekstenel olarak bağlanmış bir ivme sensörü ile titreşim verisi toplayarak gerçekleştirilmiştir. Sensör, 26 kHz bir frekansta veri örnekleme yapmıştır. Bir ölçüm 2.6 saniye sürmüştür. Bir hafta boyunca saatte bir ölçüm alınmak üzere 56 gün boyunca ölçümler yapılmıştır. Ölçüm sırasında, robot ikinci eksenin 90° hareket aralığında izole bir hareket gerçekleştirmiştir. Kalan süre boyunca, robot aşınmayı hızlandırmak için değişken açısal hızlara sahip karmaşık bir trajetori gerçekleştirmiştir. Robotun sağlık durumunu izlemek için kök ortalama kare (RMS) özelliğini seçtik. Toplanan verilere dayanarak, her ölçüm için RMS'yi, ölçüm başına N örneği ve örnekleme başına ölçüm değeri x_i 'ye dayanarak formüle göre hesapladık.





Figure 7: Raw acceleration signal of one measurement

$$RMS = \sqrt{\frac{1}{N} \sum_i^N x_i^2}$$



RMS, özellikle makine durum izlemede sıkça kullanıldığı için bir özellik olarak seçilmiştir. İlk haftadaki RMS değerlerinin ortalama varyansı baz alınarak, %95 güven aralığı ve 0.05 m/s² izin verilen hata ile gerekli ölçümlerin sayısı 10 olarak belirlenmiştir. Bu sonucu doğrulamak için, bir 24 saatlik bir zaman aralığında 10 rastgele ölçüm seti için 58 seti değerlendirdik, bu ölçümlerin ortalamasını hesapladık ve bu ortalamanın 24 saatlik ortalama ve izin verilen hata aralığının içinde olup olmadığını doğruladık. Bu yaklaşım, ölçümlerin %90'ının belirlenen hata aralığında olduğunu göstermiştir. Kullanılan veri aşağıda gösterilmiştir. Mavi renkteki veriler, orijinal RMS değerlerini temsil eder. Turuncu renkteki veriler, 24 saatlik bir zaman aralığında üç örneğe dayanarak tahmini verileri gösterir. Yeşil ve kırmızı çizgi, 0.05 hata için 24 saatlik ortalama için %95 güven aralığını belirler. Orijinal verilerin çoğu bu aralıkta bulunmaktadır. Sadece bazı yüksek değerli pikler bu aralığın dışındadır (%10'lık ölçümlerin çoğu).

Örnek 2

[Data_analytics_for_predictive_maintenance_of_industrial_robots.pdf](#)

Bu basit örnekte kullanılan endüstriyel robot, sürekli ve noktasal yol görevleri için eklemli kol kinematiğine sahip, çok amaçlı ve kompakt KUKA KR 6-2 modelidir. AC servomotorlarla çalışan altı eksenli bu robotun motor kapasitesi 8,8 kW ve tekrarlanabilirliği 0,05 mm'dir. Ayrıca, birçok endüstriyel alanda kullanılan 6DOF izleme yeteneğine sahip bir koordinat ölçüm cihazı olan LTD800 Leica Laser Tracker'ı kullandık.




Fig. 3. Robot positions modeling.

Öncelikle robotun elektrik sinyalinin bir dizi özellik(feature) çıkarmayı ve bunların birbirleriyle olan korelasyonunu analiz etmeyi öneriyoruz. Aşağıdaki özellikleri kullanmayı öneriyoruz: Ortalama, Standart sapma, Basıklık(Kurtosis), Çarpıklık(Skewness), Periyodiklik (Uzun süreli ve Kısa süre) ve Enerji. Bu istatistiksel göstergelerin formülü kolayca ulaşılabilir o yüzden yazılmamıştır.

Robot, belirli bir süre boyunca A ve B noktaları arasında tekrar eden hareketler yapacak şekilde programlandı. Aynı anda, lazer izleyici, robotun hareketi sırasında uç efektörün farklı pozisyonlarını 100 Hz hızında kaydetti. Referans yörünge ilk olarak tanımlandı. Referans mekansal pozisyonlar veri setini oluşturmak için robotun hareketi, saniyede 800 kayıt hızında 10 dakika boyunca izlendi ve X, Y ve Z eksen koordinat değerlerinden oluşan 20000'den fazla kayıt elde edildi. Referans eğri, XZ düzleminde lineer regresyon eğri uydurma yöntemiyle elde edildi. Bu modele dayanarak, robot uç efektörünün yeni izlenen pozisyonlarının doğruluğu, bu noktaların referans modeline göre MSE değerleri hesaplanarak elde edildi. Eğitim aşaması için, robot hareketi sırasında kaydedilen akım ve robot pozisyon verilerinden 18 dakikalık bir veri seti hazırlandı. Özellik çıkarımı yaptıktan sonra, her biri 3 fazlı akımlardan 8 özellik içeren ve 155 satır (gözlem) ile farklı profillere karşılık gelen 24 sütundan oluşan bir özellik vektörü elde ettik.

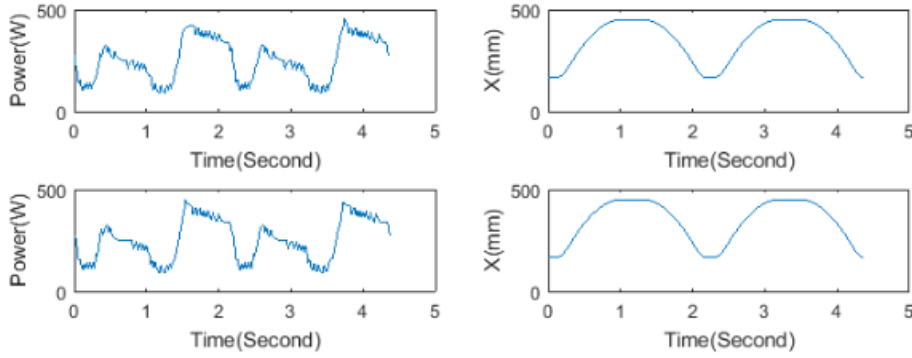



Fig. 6. Two consecutive profiles extracted from the Power and X coordinates data sets



Son olarak, veriyi çoklu doğrusal regresyon modeline oturttuk. Elde edilen modelin katsayıları ve spesifikasyonları belirlendi. Modelin kalitesini değerlendirmek için residuallar histogramı plotu kullanılarak residualların aralığı ve frekansları gösterildi. Bu histogram, residualların neredeyse normal bir dağılıma sahip olduğunu ve dış değerlerin olmadığını, bu da elde edilen modelin uyum iyiliğini vurguladığını göstermektedir. Modelimizin doğruluğunu daha iyi anlamak için, doğruluk hatasının tahmin edilen değerlerini gözlemlenen değerlerine karşı plotladık. Bu plot, modelin tahminleri ile gerçek sonuçları arasında güçlü bir korelasyon olduğunu göstermektedir ki bu, kullanılan eğitim verilerinin küçük boyutuna rağmen modelin tatmin edici doğruluğunu yansıtmaktadır. Elde edilen RMSE 0.0916 ve dolayısıyla MSE 0.008 olup, bu değer sıfıra çok yakındır.

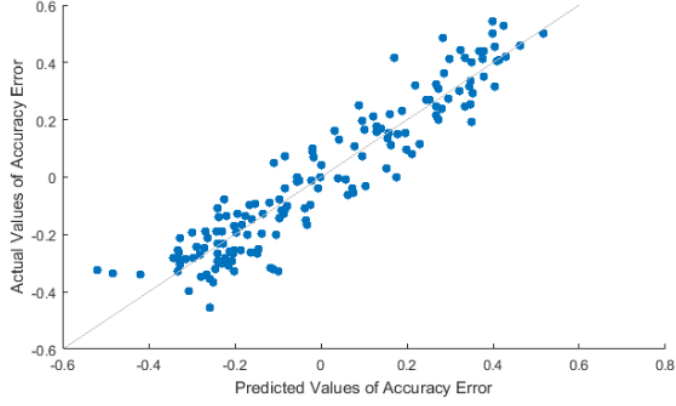


Fig. 12. Plot of Predicted vs Observed Values of Accuracy Error

Sonuç

Robot manipölörlerinin kestirimci bakımı için veri odaklı doğruluk hatası tespit yaklaşımı önerilmiştir. Belirtilen kestirimci modelleme metodolojisi, doğruluk hatasını tahmin etmek için robot güç zaman serilerinin veri analizine dayanır. Deneysel sonuçlar, robotun 3 fazlı akımının bir dizi elektriksel özelliği ile doğruluk değerleri arasında nispeten güçlü bir korelasyon olduğunu göstermiştir. Elde edilen kestirimci model, ölçülen güç verilerine dayalı olarak doğruluk hatalarını tahmin etmede tatmin edici bir uyum iyiliği ve yüksek kullanılabilirlik göstermiştir.